

RECONHECIMENTO DE PADRÕES DE
CANDLESTICKS UTILIZANDO DEEP LEARNING

PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL

ALUNO: Gabriel Vinicius Boin Freitas
ORIENTADOR: Marcelo Cohen

Sumário

1. RESUMO	2
2. INTRODUÇÃO	3
3. TRABALHOS RELACIONAIS	7
4. METODOLOGIA	12
5. RESULTADOS	22
6. DISCUSSÃO	23
7. CONCLUSÃO E TRABALHOS FUTUROS	25
8. AGRADECIMENTOS	26
9. REFERÊNCIAS BIBLIOGRÁFICAS	27

1. RESUMO

Com o avanço do machine learning e especialmente das redes neurais convolucionais, que compõem o deep learning, na segunda metade da década de 2010, muitos autores tentaram elaborar como reconhecer automaticamente padrões de candlestick em um gráfico, de forma probabilística.

Alguns realizam encoding das séries temporais que compõem um candlestick e então utilizam redes neurais convolucionais para classificar os padrões e, outros, utilizam a representação 2d do próprio gráfico de candles para ser analisado pelo deep learning, mas, o mais assertivo, que aparece já no começo de 2023, é utilizar a implementação determinística algorítmica para tal feita.

Mesmo assim, nada impede ou desabona a utilização das técnicas de inteligência artificial para descoberta de novos padrões e construção de incrementos à teoria dos candlesticks.

O artigo aplica transfer learning, data augmentation, dropout e batch normalization para treinamento de rede neural convolucional de referência (pré-treinada) VGG19, e consegue resultado de acerto na classificação de 68%, superior ao artigo de referência utilizado para comparação que obteve taxa de acerto de 62%, porém, inferior ao resultado obtido em artigos que utilizam encoding do gráfico de candlestick antes do treinamento da CNN.

A utilização de uma rotulagem automática dos padrões de candle, através de algoritmo determinístico e posterior treinamento de CNN utilizando-se a mesma metodologia deste artigo pode aumentar a assertividade e utilidade do modelo.

2. INTRODUÇÃO

Em cada segundo, em todo planeta, existem inúmeras transações de compra e venda de ativos em bolsas de valores.

Os preços de ações de empresas nos mercados de capitais variam constantemente, pois, refletem, nas ordens de compra e venda dos investidores, as expectativas do mercado em relação ao valor da empresa que aquela ação representa uma parcela.

Poder prever corretamente a tendência, de subida ou descida, no preço de uma ação, pode gerar ganhos financeiros e diminuir riscos de investimentos.

Muitas são as formas de tentar entender os preços dos ativos listados na bolsa.

Basicamente, existem 2 tipos:

- análise fundamentalista, que analisa vários indicadores pertinentes à empresa e ao mercado e precifica o valor justo de um ativo, de forma que as flutuações no preço de compra e venda das ações reflitam sentimentos diferentes dos investidores quanto a algumas variáveis discricionárias na precificação dos ativos;

- análise técnica, onde indicadores baseados em análise de séries temporais auxiliam a tomada de decisões de compra e venda dos ativos, entendendo que o preço segue certa lógica cíclica do mercado.

Pensando no segundo grupo de técnicas, do Japão, no final do século XX, para todo o mundo, difundiu-se a técnica de candlestick.

O gráfico de candlestick, candelabro, em inglês, nasceu na forma de se registrar as variações dos preços no mercado de arroz japonês.

Analisando estes gráficos, foram descobertos padrões no conjunto de velas que indicavam maior chance de subida ou descida nos preços dos arroz nos próximos pregões.

O papa destes conceitos é um dos livros mais famosos sobre o assunto é (NISON, 1994). Neste livro, ele conceitua o que são os candles, velas, em

inglês, e os candelabros, candlesticks.

Candlesticks são gráficos que vão mostrar como variam os preços negociados de um ativo na bolsa de valores.




Figura 1 - Como é formado um Candle. Seu corpo é composto pelo preço de abertura e fechamento, enquanto que o preço mais alto e mais baixo do pregão fazem parte de suas sombras, superior e inferior, respectivamente. Ele representa, de forma compacta, o que ocorreu no período. O normal é ele representar um dia do pregão, para determinado ativo. Fonte: (CHEN; TSAI, 2020)

Cada candle é um período de pregão, normalmente um dia, mas podem ser criados candlesticks onde cada candle represente 15 minutos do pregão, ou onde cada candle represente um mês do pregão, a lógica para criação será igual e o importante é o período que cada candle representa ser uniforme, conforme apresentado na figura 1.

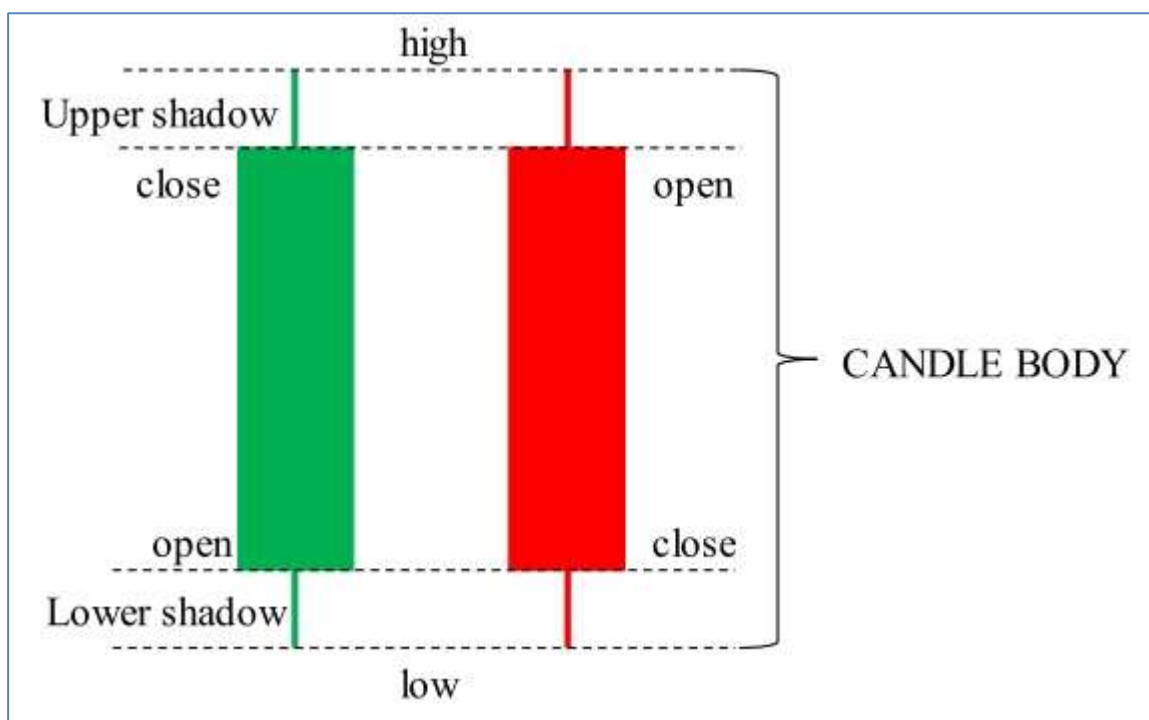


Figura 2- Exemplos de candles de alta ou baixa. O de alta em verde e o de baixa em vermelho. Fonte: (CHEN; TSAI, 2020)

Um candle é formado por alguns valores do pregão (se forem candles diários) ou período de tempo que ele representa: preço de abertura do pregão, preço mais baixo do pregão, preço de fechamento do pregão e preço mais alto do pregão.

Além disto, embaixo de cada candle, deve-se ter um gráfico de barras (uma barra por candle) que apresente o volume negociado no pregão.

Caso o pregão tenha tido alta nos preços, o candle é branco, do contrário, ele deve ser preto. Estas cores advém do Yin Yang.

Normalmente, nos softwares de mercado, se adotam o verde para candles de alta e o vermelho, para os de baixa.

O nome candle se dá por o gráfico formado pelos vários candles se parecer com um candelabro, candlestick.

A figura 2 apresenta exemplos de candles de alta (verde) e baixa (vermelho).

Pattern (duration in candles)		
<i>Low reliability</i>	<i>Fair reliability</i>	<i>High reliability</i>
Doji (1)	BreakAway (5)	Closing Marubozu (1)
Gap Side Side White	Doji Star (2)	ConcealBabysWall (4)
Three Crows (3)		
Hammer (1)	Dragonfly Doji (1)	Counter Attack (2)
Hanging Man (1)	Engulfing (2)	Dark Cloud Cover (2)
Harami (2)	Gravestone Doji (1)	Evening Doji Star (3)
Harami Cross (2)	Hikkake (3)	Evening Star (3)
High Wave (1)	Hikkake Mod (3)	Falling Three Methods (3)
Inverted Hammer (1)	Homing Pigeon (2)	Identical Three Crows (3)
Long Leggend Doji (1)	Ladder Bottom (5)	In Neck (2)
Rickshaw Man (1)	Long Line (1)	Kicking By Length (2)
Separating Lines (2)	Matching Low (2)	Kicking (2)
Shooting Star (1)	On Neck (2)	Maruzobu (1)
ShortLine (1)	Piercing Line (2)	Mat Hold (5)
SpinningTop (1)	StalledPattern (3)	Morning Doji Star (3)
Takuri (1)	Stick Sandwich (3)	Morning Star (3)
Three Line Strike (3)	Tasuki Gap (3)	Rising Three Methods (3)
Thrusting (2)	Three River (3)	Three Black Crows (3)
	Three Stars in the South (3)	Three Inside Up (3)
	Three White Soldiers (3)	Three Outside Up (3)
	Tri-Star (3)	Upside Gap Two Crows (3)
	Two Crows (3)	
	Upside Gap Three Methods (3)	

Figura 3- Exemplos de padrões de candlestick com seu grau de certeza e quantos períodos os compõem. Fonte: (CAGLIERO; FIOR; GARZA, 2023)

Conjuntos de candles são nomeados por (NISON, 1994) e vários padrões são identificados, como tendo efeitos de uma possível alta ou baixa, nos períodos que os seguem. A figura 3 apresenta vários padrões famosos.

Conforme será apresentado na seção de trabalhos relacionados, há varias iniciativas para se identificar automaticamente os padrões de candlestick nos gráficos, de forma a facilitar a análise do investidor que não possui conhecimento profundo sobre o assunto, mas que quer obter um prognóstico utilizando tal técnica, informando se o mercado irá subir ou cair.

Além disto, automatizar a identificação dos padrões de candlestick ajuda a criar modelos mais sofisticados de trading por robôs e pode contribuir para validar e incrementar a própria teoria que cunhou os padrões de candlestick.

3. TRABALHOS RELACIONAIS

Em 2015, (WANG; OATES, 2015), inaugura a utilização das técnicas Gramian Angular Summation/Difference Fields GASF e GADF; e Markov Transition Fields (MTF)¹, para transformar uma série temporal em imagens e utilizar estas imagens, depois depadronizadas, na sua classificação, utilizando uma CNN², fazendo a aplicação em 20 bases de dados conhecidas e obtendo bons resultados com o método.

Conseguiu um menor MSE³ em 12% a 48%, em comparação às abordagens de comparação, além de ter vencido como sendo o melhor modelo em 9 das 20 bases usadas.

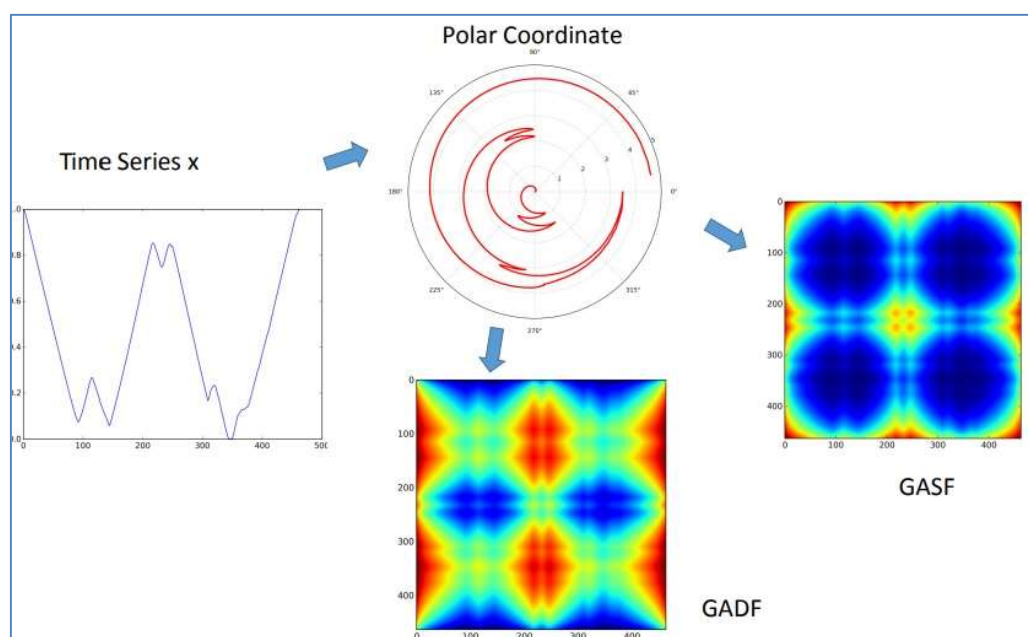


Figura 4 - Encoding usando o GASF / GADF. Primeiro, se interpola os valores da série temporal em um gráfico de coordenadas polar. Num segundo momento, utilizando fórmulas, se calcula o GASF e GADF e se constrói duas matrizes. Ao final, se cria um heatmap para cada uma das matrizes geradas. Estas imagens geradas serão enviadas para uma CNN. Fonte: (WANG; OATES,

¹ Gramian Angular Summation / Difference Fields GASF e GADF são utilizados para transformar uma série temporal em imagem da seguinte forma: Primeiro, se interpola a série em um gráfico polar, utilizando-se de arco cossenos da série transformada no intervalo de $[-1a1]$ ou de $[0a1]$, de forma em que o tempo seja o raio no gráfico. Em um segundo momento, se calcula o valor de GASF/GADF, utilizando suas fórmulas. Depois disto, é criado um heatmap para as 2 matrizes geradas. Também é feito o encoding das séries temporais utilizando-se da técnica de Markov Transition Fields (MTF). (Esta técnica é apresentada na figura 4).

² CNN é acrônimo de Convolutional Neural Network, rede neural convolucional.

³ MSE quer dizer Mean Square Error, erro quadrático médio. Verifica-se a diferença entre o valor previsto e o valor esperado/conhecido, eleva-se ao quadrado, soma-se todos os desvios e se calcula a média.

Em 2018, (HATAMI; GAVET; DEBAYLE, 2018), apresenta como transformar uma série temporal em uma imagem utilizando Recurrence Plot⁴.

Esta imagem é padronizada e então passa por uma rede neural convolucional, para classificar cada série temporal. São utilizadas as mesmas bases de dados que (WANG; OATES, 2015) e com a nova forma de gerar as imagens, a metodologia se apresentou mais assertiva, obteve 10 vitórias nas mesmas 20 bases.




Figura 5 - Encoding usando o Recurrence Plot. Em um primeiro passo, a série temporal (uma dimensão: o valor x e o tempo) é transformada em uma matriz de coordenadas (x,y) , onde x é cada valor no tempo t , e y , o valor em $t+1$. No segundo passo, é construída a imagem a partir de um heatmap da distância entre cada ponto (x,y) criado na matriz. Fonte: (HATAMI; GAVET; DEBAYLE, 2018)

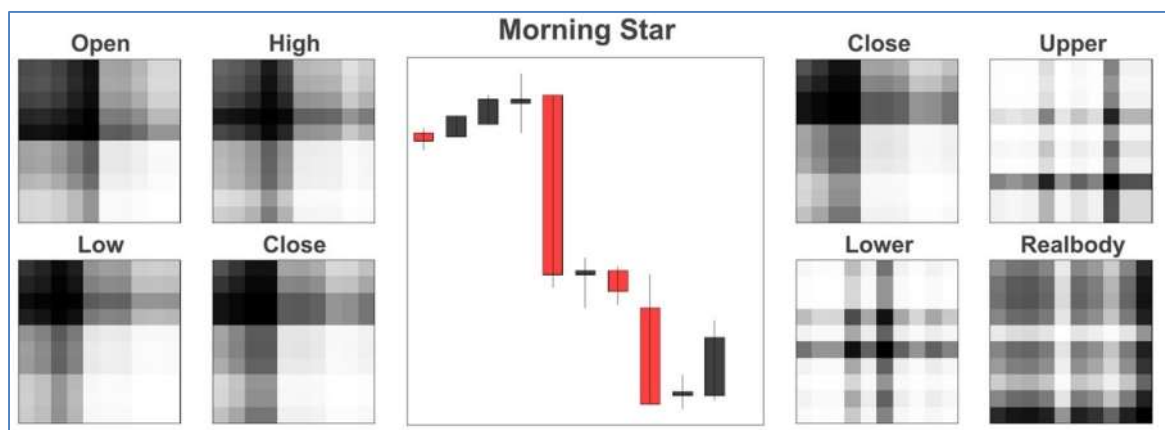


Figura 6 - Encoding das séries temporais que formam o candlestick. Exemplo de um padrão mourning star com encoding. Do lado esquerdo do padrão de candlestick, OHLC e do lado direito, CULR. Fonte: (CHEN; TSAI, 2020)

No artigo (CHEN; TSAI, 2020), é utilizada a técnica de Gramian Angular Fields, utilizada em 2015, para fazer o encoding em imagens de 8 padrões de

⁴ Recurrence Plot: Em um primeiro passo, a série temporal (uma dimensão: o valor x e o tempo) é transformada em uma matriz de coordenadas (x,y) , onde x é cada valor no tempo t , e y , o valor em $t+1$. No segundo passo, é construída a imagem a partir de um heatmap da distância entre cada ponto (x,y) criado na matriz. A técnica é ilustrada na figura 5.

candlestick.

É utilizada uma janela temporal de 10 candles para a criação de 8 imagens que representam 2 conjuntos de séries temporais que compõem a evolução de 10 candles OHLC⁵ ou CULR⁶.

Ambos conjuntos de 4 imagens são usados para treinar a rede neural convolucional, um de cada vez, e se verifica que a utilização do CULR é mais performática para a classificação dos padrões de candles. 92,42% de acurácia média.

Neste artigo, o autor cunha o termo Financial Vision, como técnica para se enxergar padrões financeiros pela máquina. A figura 6 apresenta esta técnica de encoding para um padrão de candlestick, mourning star.

Ainda, em 2020, (CHEN et al., 2020), utiliza técnica de ataque adversário⁷ no modelo criado em seu artigo anterior para demonstrar que o modelo de rede neural convolucional⁸, realmente aprendeu a reconhecer os 8 padrões de candlestick propostos.

Pela publicação (SHAH, 2020), o autor apresenta código em Python de geração automática dos gráficos de candlestick para um conjunto pré-definido de ativos, com labelling automático das imagens em duas classes: Up (padrões de alta) e Down (padrões de baixa).

O código utiliza a biblioteca fastai do Python para realizar data augmentation, reduzindo overfitting e o autor utiliza transfer learning da rede profunda pré-treinada resnet34⁹.

Ele consegue acurácia de 62% no reconhecimento de padrões de alta ou baixa de candles, porém, sem classificá-los em suas nomenclaturas originais.

O autor utiliza heatmap em gráficos candlestick onde os padrões de alta

⁵ OHLC : Opening, high, low, closing prices. Preço de abertura, maior preço, menor preço e preço de fechamento do pregão.

⁶ CULR: Closing prices, upper shadow, lower shadow, real-body. Preço de fechamento do pregão, tamanho da sombra superior, tamanho da sombra inferior e tamanho do corpo do candle, que é a diferença entre o preço de abertura e fechamento.

⁷ Ataque adversário é uma técnica que tenta enganar a rede utilizando-se de imagens que contém pixels propositadamente modificados de forma que ativem certos nodos específicos que farão a rede errar a classificação. Se a rede aprendeu de forma superficial um problema de classificação, poderá cair mais facilmente neste tipo de ataque, caso contrário, é possível utilizar tal técnica para mostrar que a rede aprendeu features robustas no tratamento do problema de classificação em questão.

⁸ CNNs e modelos de deep learning em geral têm sua explicabilidade mais complexa do que modelos de Machine Learning mais simples. Redes neurais são chamadas de caixas pretas por muitos autores. Existem muitas técnicas de visualização das camadas intermediárias que podem mitigar tal situação.

⁹ Resnet34 é uma CNN de referência, pré-treinada, para classificação de imagens. Ela utiliza técnica de aprendizado residual em sua arquitetura. Mais informações podem ser obtidas em <https://www.kaggle.com/datasets/pytorch/resnet34>.

ou baixa foram identificados, de forma a iluminar a região onde um padrão relevante acontece.

No trabalho de (BIROGUL; TEMÜR; KOSE, 2020), é utilizada a tecnologia YOLO¹⁰, para identificar padrões de candlestick, fornecendo um sinal de compra ou venda do ativo, que junto com outros indicadores da análise técnica de preços de ativos, consegue se performar corretamente de forma automática no mercado de ações em 83,93% dos casos estudados.

Neste trabalho, também não são classificados os candlesticks em suas várias classes, mas sim, apenas, padrão de alta ou baixa.

Em 2021, no artigo (XU, 2021), utiliza o encoding dos candlesticks baseados na técnica de GAF, similar ao realizado em (CHEN; TSAI, 2020), porém, utiliza técnicas mais simples de machine learning para a classificação dos padrões de candlestick, concluindo que XGBoost¹¹ obteve melhores resultados do que a aplicação de uma rede neural convolucional profunda.

Utilizando YOLO, também, (PATHAK; TAMBOLI; TAMBOLI, 2022) treinam modelo com padrões pré-definidos de candlestick e obtém bons resultados. Não especificam a acurácia no artigo, porém, apresentam como utilizar um software de labelling¹² – Labelling Software, para poder classificar os candlesticks antes de treinar o modelo YOLO.

Em 2022, (CHEN; TSAI, 2022) utilizam YOLO junto com sua técnica de transformar o padrão candlestick em um conjunto de 4 imagens que o representa, (CHEN; TSAI, 2020), e obtém bons resultados, 88,35% de acurácia média na detecção em tempo real dos 8 padrões de candlestick propostos em 2020.

Similar ao que fazem em 2020, (CHEN et al., 2022) utilizam ataques adversários no modelo proposto em (CHEN; TSAI, 2022) para aumentar a explicabilidade deste.

(HUANG, 2022) cria um novo passo no encoding utilizando GAF, onde

¹⁰ YOLO: you only look once, é uma arquitetura de CNN pré-treinada que consegue detectar e classificar imagens de forma muito rápida porque não faz em 2 estágios a tarefa, utiliza mascaras pré determinadas para a detecção, de forma a reduzir o problema. Ela tem como objetivo detectar e classificar as imagens praticamente em tempo real.

¹¹ XGBoost é um algoritmo de aprendizado de máquina, que não utiliza rede neural profunda. Mais informações em <https://xgboost.readthedocs.io/en/stable/>.

¹² Labelling, que quer dizer rotular, é a técnica de se escolher a área da imagem onde está presente determinado padrão e colocar uma classe correspondente a ela, para ser possível a realização do treinamento supervisionado em seguida.

ele transforma em uma imagem RGB¹³, que consegue evitar certas redundâncias verificadas no encoding GAF simples.

Ele utiliza data augmentation nas séries temporais utilizando o modelo ARIMA¹⁴ junto com uma rede neural convolucional e depois, através de YOLO treinado com os dados aumentados, consegue fazer a classificação dos padrões de candlestick.

Em seu livro de janeiro de 2023, (KAABAR, 2023) apresenta, de forma detalhada e com o código em Python, como reconhecer os padrões clássicos de candlestick de forma totalmente algorítmica, e, por tanto, determinista.

Além disto, ele inclui alguns novos padrões modernos em que analisa serem úteis para a teoria dos candlesticks.

Ele analisa a força dos vários padrões de candlestick em diversos ativos e mercados e apresenta diversas estratégias automatizadas de trading, utilizando os modelos determinísticos de reconhecimento de padrões de candles e outros indicadores financeiros utilizados nas previsões de mercado.

No artigo de janeiro de 2023 de (CAGLIERO; FIOR; GARZA, 2023), os autores utilizam biblioteca¹⁵ implementada em Python, que também identifica os padrões de candlestick de forma determinística, com algoritmos, e a partir deste reconhecimento e agregando mais indicadores financeiros à análise, utilizam modelos clássicos de machine learning para prever se o mercado vai subir ou descer com as várias configurações de padrões de candlestick junto com indicadores financeiros técnicos.

¹³ RGB quer dizer Red, Green and Blue, vermelho, verde e azul, e são os canais que uma imagem possui ao ser apresentada na tela de um computador. Para cada um dos canais, existe uma matriz com um número de 0 a 255 para os pixels que representam a imagem. Com isto, é possível a criação das cores no vídeo.

¹⁴ ARIMA Autoregressive integrated moving average, média móvel integrada auto regressiva é uma técnica para análise de séries temporais.

¹⁵ Biblioteca: Python-based Technical Analysis Library : <https://github.com/quantopian/ta-lib>

4. METODOLOGIA

Em primeiro lugar, foi criado um notebook no Google Colab para poder refazer, passo a passo, o que foi feito em (SHAH, 2020).

Foi escolhido este trabalho por apresentar um código didático, limpo e por se entender que um modelo que reconheça os padrões de alta e baixa, sem utilizar classes previamente criadas pela teoria dos candles, poderia ser interessante, já que a modelagem pode identificar mais classes e padrões do que o olho humano e sua teoria.

Já se tem documentado no levantamento bibliográfico, livro que aborda de forma determinística o problema.

(SHAH, 2020) utilizou conceitos como data augmentation, transfer learning, uma rede pré-treinada e conhecida, a resnet34, e não utilizou interpolações ou imagens derivadas daquela que um gráfico de candlestick em 2d apresenta, apresentando à rede convolucional a imagem tal qual o humano vê, o que ajuda a exploração deste campo de novos possíveis padrões de candlestick.

Foram utilizadas, no primeiro momento, todas as parametrizações e ativos selecionados por (SHAH, 2020).

A janela que ele decidiu para criar os candlesticks foi de 15 dias, sendo cada candle, um dia.

Ele classificou os candlesticks em Up ou Down, caso nos próximos 5 pregões juntos, houvesse um aumento ou declínio superior a 3,70%.

Caso não houvesse movimento de alta ou baixa, o script não gerava o candlestick.

A ideia seria classificar futuros candlesticks em Up ou Down apenas se a porcentagem indicada pelo modelo para determinada classe atingisse um threshold¹⁶ alto, já que não havia, no treinamento, classe neutra.

Para aumentar a velocidade, foi contratado o pacote do Google Colab Pro, utilizado acelerador via Tensor Processor Unit - TPU e o aumento da

¹⁶ Threshold pode ser traduzido como "limiar".

memória RAM disponível para 32,5 GB.

Para fins de registro à posteridade, o valor da assinatura mensal PRO, que dá direito a 100 unidades de processamento por mês, acesso a mais memória RAM que o normal, o padrão seria 12 GB, e possibilidade de utilização de GPUs e TPUs foi de R\$ 58,00.

Anteriormente, em testes, cada época estava demorando 12 minutos para rodar e o ambiente travava por falta de memória RAM, depois do upgrade, cada época é processada em um minuto e o ambiente chegou a consumir no máximo 25 GB de RAM, tendo memória de sobra.

Seria inviável realizar os experimentos sem o ambiente contratado da nuvem, com os recursos atuais disponíveis no equipamento local do autor. O preço pareceu justo pela entrega de performance conseguida.

epoch	train_loss	valid_loss	error_rate	time
0	1.387497	1.033692	0.493023	01:24
1	1.275627	1.050920	0.483721	01:04
2	1.096563	0.818640	0.460465	01:10
3	0.967336	0.793957	0.460465	01:08

Figura 7 - Treinamento inicial.

Primeiro, o modelo de (SHAH, 2020) foi treinado com 4 épocas e com a métrica de treinamento error rate.

Foi conseguida uma error rate de 46% no primeiro ciclo, melhor que os 48% conseguido por ele em sua publicação. A figura 7 ilustra este passo.




Figura 8 - Buscando learning rate ótima.

Foram descongelados os pesos da rede e então utilizada a procura da melhor learning rate¹⁷, se plotando o gráfico de loss vs learning rate (figura 8) e verificado que a taxa ideal estaria entre 1e-4 e 1e-3.

epoch	train_loss	valid_loss	error_rate	time
0	0.832339	0.824531	0.418605	01:28
1	0.824472	0.803320	0.483721	01:28
2	0.788142	0.770923	0.451163	01:30
3	0.727796	0.675664	0.374419	01:29
4	0.664248	0.669214	0.362791	01:29

Figura 9- Segundo ciclo de treinamento.

Foi rodado, então, novo ciclo de treinamento, com este range de learning rate e com 5 épocas. Conseguiu-se uma error rate de 36% já neste segundo ciclo, superior a relatada no final do artigo do autor, de 38% (figura 9).

¹⁷ Learning rate é a taxa de aprendizado, parâmetro bastante importante em uma CNN, e vai determinar o tamanho do passo do algoritmo para encontrar o mínimo da função de custo que ele busca minimizar.




Figura 10 - Buscando learning rate ótima depois do segundo ciclo.

epoch	train_loss	valid_loss	error_rate	time
0	0.572904	0.648913	0.332558	01:29
1	0.548967	0.728142	0.362791	01:26
2	0.573034	0.796656	0.420930	01:18
3	0.564277	0.672823	0.341860	01:18
4	0.519322	0.738442	0.330233	01:20
5	0.480038	0.620905	0.295349	01:19
6	0.419189	0.561065	0.253488	01:18
7	0.356243	0.501201	0.202326	01:17
8	0.296227	0.523095	0.209302	01:19
9	0.252419	0.511463	0.197674	01:20

Figura 11 - Terceiro ciclo de treinamento.

Continuou-se o treinamento, repetindo o passo de identificar o melhor range para a learning rate, e então sendo rodado um ciclo de treinamento com 10 épocas, tal qual realizado pelo autor. A melhor learning rate ainda estaria entre $1e-4$ e $1e-3$. O resultado deste ciclo foi uma error rate de 19%, porém, um desequilíbrio entre a train loss e a valid loss 0,252419 vs 0,511463, indicando um possível overfitting (figuras 10 e 11).




Figura 12 - Buscando learning rate ótima depois do terceiro ciclo.

epoch	train_loss	valid_loss	error_rate	time
0	0.170199	0.548781	0.218605	01:21
1	0.180584	0.602361	0.216279	01:25
2	0.180240	0.629916	0.227907	01:31
3	0.168816	0.609869	0.227907	01:25
4	0.148105	0.614111	0.225581	01:23

Figura 13 - Quarto ciclo de treinamento.

Continuou-se procurando a melhor learning rate novamente e então executado um ciclo de treinamento com 5 épocas.

A learning rate utilizada foi de no máximo $1e-4$ e obteve-se uma error rate de

22,55%, maior do que a anterior e com o modelo mais overfittado, sendo train loss e a valid loss 0,148105 vs 0,614111 (figuras 12 e 13).

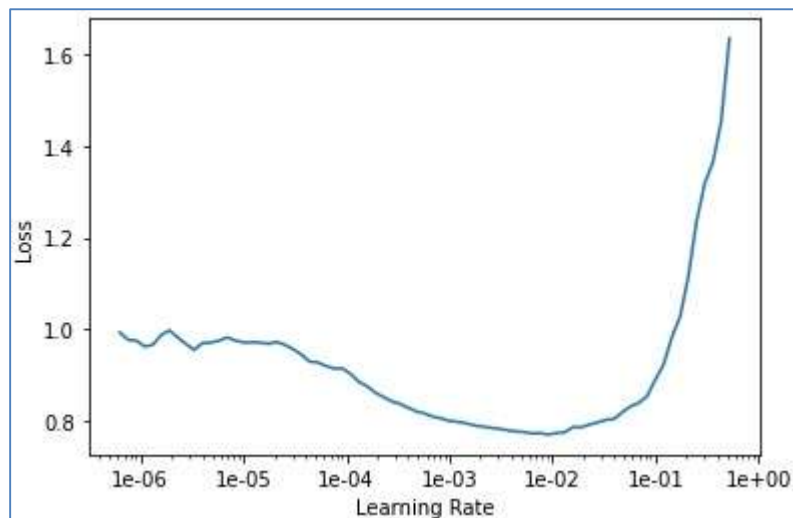


Figura 14 - Buscando learning rate ótima depois do quarto ciclo.

epoch	train_loss	valid_loss	error_rate	time
0	0.782334	1.786913	0.469767	03:00
1	0.873269	41.905727	0.458140	02:59
2	0.882582	0.845861	0.502326	02:52
3	0.850927	0.754046	0.500000	02:53
4	0.820880	0.689208	0.483721	02:51

Figura 15 - Quinto ciclo de treinamento.

Tal qual (SHAH, 2020) realizou, foi salva uma primeira versão do modelo e então rodado um novo data augmentation para começar novo ciclo de treinamento com 5 épocas e learning rate descoberta em $1e-3, 1e-2$, conseguindo-se uma error rate de 48,37% , mas com um equilíbrio maior entre train loss e a valid loss 0,820880 vs 0,689208 (figuras 14 e 15).




Figura 16 - Buscando learning rate ótima depois do quinto ciclo.

epoch	train_loss	valid_loss	error_rate	time
0	0.770445	0.687980	0.453488	02:49
1	0.755654	0.686953	0.453488	02:52
2	0.746153	0.687028	0.446512	02:51
3	0.753909	0.686692	0.462791	02:50
4	0.762665	0.687047	0.467442	02:51

Figura 17 - Sexto ciclo de treinamento.

Mais um ciclo foi rodado com 5 épocas e learning rate no intervalo de $1e-6$ a $1e-5$, obtendo-se o resultado de error rate de 46%, superior ao que o autor havia chegado em sua publicação, de 38% (figuras 16 e 17). O modelo foi salvo novamente. As previsões foram realizadas utilizando-se o threshold de 75% para poder classificar em uma das classes.

A classificação ficou zerada com este threshold, diferente do que o autor apresentou.

Diminuiu-se o threshold para 50% (foi se diminuindo de 5 em 5 pontos percentuais até haver classificações).



Figura 18 - Modelo se baseando no volume de trading para a classificação.

Verificou-se que o modelo aprendeu a classificar entre padrões Up e Down de forma pouco assertiva tendo como pontos principais para determinação da classe, não o padrão de candlestick observado, mas sim, o padrão de volume e suas cores observadas.

A figura 18 apresenta esta situação, iluminando quais os pixels que mais ativam a rede para a realização da classificação. Foram gastas 7 unidades de processamento do Google Colab Pro neste experimento.

Foi repetido o experimento apenas fazendo o primeiro data augmentation e colocando-se 20 épocas em um ciclo.

Conseguiu-se error rate de 40,93%, com equilíbrio entre validação e teste.




Figura 19 - Modelo reconhece padrão de candlestick de alta.

Percebeu-se que na época 16 a taxa de erro era de 39,77% com equilíbrio maior entre validação e teste.

Este resultado ficou próximo do mencionado no artigo original, sendo possível utilizar o threshold de 75% e funcionando o heatmap proposto pelo autor para mostrar que o padrão de candle foi aprendido(figura 19). Neste experimento foi gasta apenas 1 unidade de processamento.

A ideia para o próximo experimento foi executar o mesmo que o anterior, porém, com os dados de todas ações que compõem o índice Bovespa em dezembro de 2022.

A janela de 15 dias para a criação dos vários candlesticks foi revista, alterada para 5, visto que o maior valor em dias que compõe os padrões na bibliografia é de 5 pregões.

Além disto, foram consideradas as tendências de alta ou queda, quando nos 5 primeiros dias depois do surgimento do padrão ocorressem aumento ou queda acumulada maior ou igual a 15%, devido à alta volatilidade do mercado acionário brasileiro.

Foi coletado o período de 2022, garantindo informações de todas as ações que constam no índice e se esperando uma boa amostra de candlesticks de altas e baixas. Os resultados foram semelhantes aos conseguidos no experimento 2.

Em um quarto experimento, tentou-se aumentar o tamanho da base de dados, considerando a magnitude de 10% para classificação de altas ou baixas dos ativos que compõe o ibovespa em 2022.

Tentou-se utilizar magnitude de 5%, porém, excedeu-se a capacidade de memória RAM disponível no ambiente pela quantidade de casos encontrados, que gerou demasiada quantidade de imagens.

Investiu-se 10 unidades de processamento e 2 horas de espera na tentativa de magnitude 5%.

O resultado com a magnitude 10% foi muito próximo do conseguido com 15% e também com o conseguido na base original, com os ativos escolhidos por (SHAH, 2020), mesmo tendo-se rodado 40 épocas em 2 ciclos de treinamentos, a error rate ficou em torno de 42%. O modelo iluminou o padrão de candlestick, porém é pouco assertivo também.

Foi tentado, em uma variação do experimento anterior, utilizar-se de dropout ¹⁸e de um treinamento mais lento, com paradas para utilizar-se da função de descoberta das melhores learning rates em cada estágio do treinamento, mas obteve-se o mesmo resultado.

Em um quinto experimento, utilizou-se a rede neural de referência VGG19¹⁹ com batch normalization²⁰ e dropout de 80%.

A rede foi treinada de forma lenta, com busca pela melhor learning rate a cada 10 épocas, sendo que o primeiro ciclo possuiu 16 épocas.

Houveram 5 ciclos de treinamento e cada um demorou, em média, uma hora. Foram consumidas 30 unidades de processamento do Google Colab.

Chegou-se a uma error rate de 32%, desempenho superior à error rate do artigo de (SHAH, 2020), de 38%.

O modelo conseguiu iluminar a área esperada do padrão de candle.

Todos códigos utilizados no trabalho estão no endereço:

<https://github.com/gabrielfea/candlestic>

¹⁸ Dropout é uma técnica de regularização dos dados que visa evitar o overfitting durante o treinamento de uma CNN.

¹⁹ VGG19 é uma rede neural de referência tal qual existe a RESNET34. Documentação sobre VGG19 pode ser obtida através do link: <https://www.mathworks.com/help/deeplearning/ref/vgg19.html>.

²⁰ Batch normalization é uma técnica de regularização no treinamento que visa suavizar o aprendizado e evitar o overfitting do modelo, que ocorre quando ele é bom para os dados de teste e ruim na generalização, quando da validação.

5. RESULTADOS

Aplicando-se a metodologia descrita, conseguiu-se resultado superior ao de (SHAH, 2020), ele teve uma taxa de acerto de 62%, enquanto neste trabalho obteve-se 68% e utilizando os ativos do índice Bovespa. A matriz de confusão e um exemplo de uma instância de candlestick da classe Up corretamente prevista com threshold de 0,75 e com a região correta ativada é vista na figura 20. O modelo atingiu acurácia de 65,43% para a classe Down e 70,32% para a classe Up, tendo acurácia média de 67,88%.



Figura 20 - Conforme visto na matriz de confusão, que é outra forma de apresentar a taxa de acerto de 68%, o modelo teve uma acurácia para a classe Down de 65,43% e para a classe Up, de 70,32%, totalizando uma acurácia média de 67,88%. Na imagem do meio é vista uma amostra de instância que é prevista para classe Up corretamente, utilizando-se de um threshold de 0,75. Para identificar se o modelo está se baseando realmente na imagem do padrão de candlestick, é iluminada a parte de interesse do modelo, que bate exatamente com o padrão de candle.

6. DISCUSSÃO

Foi verificado, através do trabalho, que a utilização do modelo proposto por (SHAH, 2020) com base de dados maior e com a rede de referência vgg19 conseguiu superar os resultados por ele alcançados.

Mesmo superando o resultado de (SHAH, 2020), 68% de assertividade não é um resultado excepcional, visto que outros trabalhos conseguiram resultados muito superiores utilizando-se de técnicas de encoding, conforme a seção de trabalhos relacionados apresenta.

A resnet34 e a vgg19 podem não ter as features necessárias em suas estruturas para a melhor distinção dos padrões de candle nas classes propostas, sem encoding: Up e Down.

Utilizar o encoding proposto por (CHEN; TSAI, 2020) parece facilitar o reconhecimento dos padrões para as redes de referência e ser o caminho mais assertivo para tal intent.

A utilização de ambiente com recursos superiores com a assinatura do Google Colab Pro foi fundamental para a possibilitação de realização dos experimentos.

O problema de pesquisa levantado desde o começo no artigo foi resolvido, conforme a revisão bibliográfica, de forma determinística, através de algoritmos, porém, toda a evolução levantada em como se utilizar redes neurais convolucionais para classificação dos padrões de candlestick, através dos encodings de séries temporais em imagens, foi bastante educativo a este pesquisador, pois foi possível entender e conhecer tais ferramentas matemáticas.

A tendência, agora, nesta seara, deve ser a utilização de técnicas de Machine Learning como redes adversárias ou outras tecnologias em prol da descoberta de novos padrões não triviais de candlestick não previstos na literatura, pois a máquina pode enxergar padrões com maior janela de tempo do que os humanos.

Para classificação nos padrões pré-existentes descritos por (NISON,

1994) , o modelo determinístico sempre será mais assertivo. Dos modelos probabilísticos levantados, que realizam a classificação dos padrões de candles automaticamente, a abordagem de (CHEN; TSAI, 2020) foi decisiva.

É elucidador entender que com o encoding utilizado por ele e lançando a mão de técnicas menos complexas de classificação, conforme verificado por (XU, 2021), se mostra mais assertivo o reconhecimento dos padrões.

Foi levantado que explorar a tecnologia YOLO é um bom caminho no aprimoramento da classificação probabilística dos candles.

A utilização do machine learning para prever o temperamento do mercado, tendo como base os sinais determinísticos passados pelos padrões automaticamente encontrados via algoritmos e os sinais de outros indicadores financeiros parece ser o caminho da utilização de inteligência artificial neste contexto.

7. CONCLUSÃO E TRABALHOS FUTUROS

Junto com a classificação e identificação automática dos padrões de candlestick e com o cálculo de diversos indicadores técnico-analíticos sobre a evolução dos preços de um ativo, pode ser um trabalho interessante a utilização de processamento de linguagem natural em fóruns especializados da web, para geração de sinal ou indicador que represente a expectativa do mercado e seus players em relação a um ativo, a ser agregado em um modelo de previsão de tendências do mercado.

Um trabalho oportuno, no que tange classificação probabilística de candlesticks, seria a repetição do trabalho de (CHEN; TSAI, 2022) no contexto da bolsa de valores brasileira, para verificação da assertividade atingida.

O artigo foi construído pela curiosidade do autor em como detectar automaticamente os padrões de candlestick em gráficos, com a ajuda da máquina.

Esta dúvida foi respondida amplamente ao longo de sua elaboração e com isto, da-se realizado o objetivo de tal feita.

A utilização de uma rotulagem automática dos padrões de candle, através de algoritmo determinístico e posterior treinamento de CNN utilizando-se a mesma metodologia deste artigo pode aumentar a assertividade e utilidade do modelo.

8. AGRADECIMENTOS

Agradeço, imensamente, à minha mulher, por sempre apoiar meus estudos e, também, a todo corpo docente da PUC-RS Online, que fez esta especialização em Ciência de Dados e Inteligência Artificial ser tão interessante, completa e agradável.

Graças a esta pós graduação, consegui os conhecimentos necessários para trabalhar na área de soluções analytics da empresa na qual colaboro, sendo que desde a metade do curso já conquistei tal posição, já fazendo a entrega de um projeto piloto neste final de ano de 2022 com modelo de previsão 400% melhor do que o que existia anteriormente.

Este artigo encaminha a solução de uma vontade/anseio/busca que me inquietava há 4 anos, desde que criei o site www.dicasdabolsa.com.br, cursando a primeira pós graduação que fiz na PUC-RS Online, Tecnologia para Negócios: DS, AI e Big Data. Sempre quis ter esta funcionalidade no site.

9. REFERÊNCIAS BIBLIOGRÁFICAS

BIROGUL, S.; **TEMÜR**, G.; **KOSE**, U. Yolo object recognition algorithm and “buy-sell decision” model over 2d candlestick charts. IEEE access, IEEE, v. 8, p. 91894–91915, 2020. Citado na página 10.

CAGLIERO, L.; **FIOR**, J.; **GARZA**, P. Shortlisting machine learning-based stock trading recommendations using candlestick pattern recognition. Expert Systems with Applications, Elsevier, p. 119493, 2023. Citado 2 vezes nas páginas 6 e 11.

CHEN, J.-H. et al. Explainable deep convolutional candlestick learner. arXiv preprint arXiv:2001.02767, 2020. Citado na página 9.

CHEN, J.-H.; **TSAI**, Y.-C. Encoding candlesticks as images for pattern classification using convolutional neural networks. Financial Innovation, SpringerOpen, v. 6, n. 1, p. 1–19, 2020. Citado 5 vezes nas páginas 4, 5, 8, 10 e 23.

CHEN, J.-H.; **TSAI**, Y.-C. Dynamic deep convolutional candlestick learner. arXiv preprint arXiv:2201.08669, 2022. Citado 2 vezes nas páginas 10 e 25.

CHEN, J.-H. et al. Explainable digital currency candlestick pattern ai learner. In: IEEE. 2022 14th International Conference on Knowledge and Smart Technology (KST). [S.I.], 2022. p. 91–96. Citado na página 10.

HATAMI, N.; **GAVET**, Y.; **DEBAYLE**, J. Classification of time-series images using deep convolutional neural networks. In: SPIE. Tenth international conference on machine vision (ICMV 2017). [S.I.], 2018. v. 10696, p. 242–249. Citado 2 vezes na página 8.

HUANG, H. Fast candlestick patterns detection with limited training samples using rgb gramian angular field and yolo-lite-v1. Stanford University, 2022. Citado na página 10.

KAABAR, S. Mastering Financial Pattern Recognition. [S.l.]: O'RELLY, 2023. Citado na página 11.

NISON, S. Beyond candlesticks: New Japanese charting techniques revealed. [S.l.]: John Wiley & Sons, 1994. v. 56. Citado 3 vezes nas páginas 3, 6 e 23.

PATHAK, L.; **TAMBOLI**, S.; **TAMBOLI**, A. Detection and analyzation of candlestick pattern using yolo object recognition. International Research Journal of Engineering and Technology (IRJET), 2022. Citado na página 10.

SHAH, S. Identifying Candlestick Patterns using Deep Learning. Shaan Shah, 2020. Disponível em: <<https://towardsdatascience.com/identifying-candlestick-patterns-using-deep-learning-b7d706726874>>. Citado 8 vezes nas páginas 9, 12, 13, 17, 20, 21, 22 e 23.

WANG, Z.; **OATES**, T. Imaging time-series to improve classification and imputation. In: Twenty-Fourth International Joint Conference on Artificial Intelligence. [S.l.: s.n.], 2015. p. 3939–3945. Citado 2 vezes nas páginas 7 e 8.

XU, C. Image-based candlestick pattern classification with machine learning. In: 2021 6th International Conference on Machine Learning Technologies. [S.l.: s.n.], 2021. p. 26–33. Citado 2 vezes nas páginas 10 e 24.